Matematički fakultet

Seminarski rad iz predmeta: Istraživanje podataka 2

Klasifikacija oglasa za posao primenom algoritama mašinskog učenja

Skup podataka: Job Descriptions

Analiza i poređenje algoritama klasifikacije

Student: Nikola Radojičić
Broj indeksa: 110/2021
Profesor: Mirjana Maljković Ružičić

Datum: 26. februar 2026.

0 Sadržaj

1 Uvod **4**
1.1 Pozadina i motivacija istraživanja . . . 4
1.2 Skup podataka . . . 4
1.3 Istraživački problemi . . . 4
1.4 Organizacija rada . . . 5

2 Podaci i priprema **5**
2.1 Izvor i struktura podataka . . . 5
2.2 Preprocesiranje . . . 5
2.2.1 Uklanjanje nedostajućih vrednosti . . . 5
2.2.2 Stratifikovano uzorkovanje . . . 5
2.2.3 Čišćenje teksta . . . 5
2.2.4 Prevođenje tekstualnih opsega u numeričke vrednosti . . . 5
2.2.5 Definisanje ciljnih promenljivih i izbor atributa . . . 6
2.3 Kreiranje skupova atributa . . . 6
2.4 Kategorizacija plate – K-Means vs. Kvantili . . . 6

3 Metod **7**
3.1 Radni tok: pregled . . . 7
3.2 Analiza uticaja broja TF-IDF reči . . . 7
3.3 Analiza kriterijuma – Decision Tree . . . 8
3.4 Poređenje skalera . . . 8
3.5 Podešavanje hiperparametara – GridSearchCV . . . 10
3.6 Algoritmi klasifikacije . . . 11
3.6.1 Logistic Regression . . . 11
3.6.2 Decision Tree . . . 11
3.6.3 Random Forest . . . 12
3.6.4 K-Nearest Neighbors (KNN) . . . 12
3.6.5 Naive Bayes . . . 12
3.7 Metrike evaluacije . . . 12
3.7.1 Tačnost (Accuracy) . . . 12
3.7.2 Makro F1 mera . . . 12
3.7.3 Cross - validacija . . . 12

4 Rezultati i vizualizacije **13**
4.1 Vizualizacija podataka – 2D PCA . . . 13
4.2 Rezultati klasifikacije – Job Role . . . 14
4.3 Rezultati klasifikacije – Work Type . . . 14
4.4 Rezultati klasifikacije – Seniority . . . 14
4.5 Rezultati klasifikacije – Salary Category . . . 15
4.6 Zbirni rezultati . . . 15
4.7 Cross-validacija . . . 16
4.8 Analiza uloge atributa . . . 16
4.9 Poređenje skupova atributa . . . 17

5 Diskusija i zaključak **17**
5.1 Analiza rezultata . . . 17

5.2 Napomena o numeričkim atributima 17
5.3 Ograničenja 18
5.4 Zaključak 18

Sažetak

U okviru ovog rada prezentujemo metode klasifikacije na 4 različita ciljna atributa skupa podataka (*Job Descriptions*). Primenjeno je 5 različitih algoritama klasifikacije (Logistic Regression, Decision Tree, Random Forest, K-Nearest Neighbors, Naive Bayes) na 4 ciljne promenljive: naziv posla (*Job Role*), tip rada (*Work Type*), nivo iskustva (*Seniority*) i kategorija plate (*Salary Category*). Atributi su kreirani kombinovanjem TF-IDF vektorizacije tekstualnih opisa i numeričkih atributa (iskustvo, plata). Evaluacija je izvršena pomoću tačnosti (*Accuracy*) i makro F1 mere, uz dodatnu validaciju putem cross-validacije. Hiperparametri Decision Tree i KNN algoritama optimizovani su primenom GridSearchCV sa 5-fold unakrsnom validacijom.

1 Uvod

1.1 Pozadina i motivacija istraživanja

Automatska klasifikacija opisa radnih mesta predstavlja važan zadatak u oblasti analize tržišta rada. Sa velikim skupovima podataka kao što je Job Descriptions sa preko 1,6 miliona instanci — ručna kategorizacija praktično da postaje nemoguća i neefikasna. Primena algoritama mašinskog učenja omogućava automatsko prepoznavanje kategorije posla, tipa radnog angažmana, nivoa iskustva i kategorije plate na osnovu tekstualnog opisa odgovornosti posla uz znatnu uštedu vremena i mogućnost primene na novim oglasima.

1.2 Skup podataka

Skup podataka *Job Descriptions* sadrži **1.615.940** instanci sa **23 atributa**, uključujući: naziv posla (`Role`), opis posla (`Job Description`), odgovornosti (`Responsibilities`), veštine (`skills`), iskustvo (`Experience`), opseg plate (`Salary Range`), tip rada (`Work Type`), lokaciju (`location`, `Country`), kao i informacije o kompaniji (`Company`, `Company Size`). Zbog velikog broja instanci, primenjen je stratifikovani uzorak od 5% po klasi ciljne promenljive `Role`, što rezultuje ukupno **80.797** instanci.

Ulazni atribut za sve modele je isključivo tekstualni sadržaj kolone `Responsibilities`, iz kojeg se kreira TF-IDF reprezentacija. Uz TF-IDF, koriste se i numerički atributi (`exp_clean`, `salary_clean`).

Definisane su **četiri ciljne promenljive**:

- **Job Role** – naziv pozicije (višeklasna klasifikacija, kolona `Role`)
- **Work Type** – tip radnog angažmana (npr. Remote, Hybrid, On-site)
- **Seniority** – nivo iskustva: Junior-Intermediate ($\leq$ 5.5 god.), Mid-level ($\leq$ 8 god.), Senior (ostalo) – kreiran iz kolone `exp_clean`
- **Salary Category** – kategorija plate: Low/Medium/High – kreirana iz kolone `salary_clean` putem K-Means klasterovanja

1.3 Istraživački problemi

1. Da li je moguće na osnovu tekstualnog opisa odgovornosti predvideti naziv radnog mesta?
2. Da li je moguće kombinovanjem tekstualnih i numeričkih atributa predvideti nivo iskustva, tip radnog odnosa i visinu plate
3. Koji algoritam klasifikacije daje najpouzdanije rezultate za različite ciljne promenljive?
4. Koliki broj TF-IDF reči je dovoljan za postizanje zadovoljavajuće tačnosti?
5. Da li MinMaxScaler ili StandardScaler daje bolje rezultate za ovaj tip podataka?
6. Koji skup atributa (samo tekst, samo numerički, ili kombinacija) daje najbolje performanse?

1.4 Organizacija rada

Rad je organizovan u pet poglavlja. Poglavlje 2 opisuje pripremu podataka i kreiranje atributa. Poglavlje 3 detaljno predstavlja primenjene algoritme i metrike evaluacije. Poglavlje 4 prikazuje rezultate i vizualizacije. Poglavlje 5 donosi diskusiju i zaključak.

2 Podaci i priprema

2.1 Izvor i struktura podataka

Skup podataka *Job Descriptions* preuzet je u CSV formatu sa sajta Kaggle. Svaki red predstavlja jedan oglas za posao. Nakon učitavanja, nazivi kolona su standardizovani (lowercase, bez vodećih razmaka).

Tabela 1: Osnovne karakteristike skupa podataka

Metrika	**Vrednost**
Ukupan broj instanci (original)	1.615.940
Broj atributa	23
Broj instanci nakon uzorkovanja (5%)	$\approx$ 80.797
Broj ciljnih promenljivih	4
Broj algoritama	5
Ukupan broj eksperimenata	20

2.2 Preprocesiranje

2.2.1 Uklanjanje nedostajućih vrednosti

Analiza nedostajućih vrednosti izvršena je pomoću `isnull().sum()` i primenom `dropna()` uklonjen je svaki red (instanca) koji sadrži bar jednu nedostajuću vrednost.

2.2.2 Stratifikovano uzorkovanje

Zbog velikog broja instanci (1.615.940) u originalnom skupu, primenjen je **stratifikovani uzorak od 5% po klasi** ciljne promenljive `Role`. Time je obezbeđena reprezentativna distribucija svih klasa u uzorku, uz značajno smanjenje računarske složenosti neopohodne za obučavanje modela.

2.2.3 Čišćenje teksta

Kolona `Responsibilities` korišćena je kao osnova tekstualnog atributa. Primenjena je sledeća transformacija: iz teksta opisa su uklonjene reči koje se pojavljuju u nazivu posla (`Role`), kako bi se sprečilo direktno "curenje" labele u atribute. Sve reči su konvertovane u mala slova, a višestruki razmaci su normalizovani. Rezultat je sačuvan u koloni (atributu) `combined_text`.

2.2.4 Prevođenje tekstualnih opsega u numeričke vrednosti

Iz kolona `Experience` i `Salary Range`, koje su u tekstualnom formatu sa opsezima (npr. *3–5 years*, *50k–80k*), generisane su numeričke vrednosti izračunavanjem aritmetičke sre-

dine intervala:

$$\text{exp_clean} = \frac{\text{min_exp} + \text{max_exp}}{2} \tag{1}$$

$$\text{salary_clean} = \frac{\text{min_salary} + \text{max_salary}}{2} \tag{2}$$

2.2.5 Definisanje ciljnih promenljivih i izbor atributa

- **Seniority** – kreirana na osnovu `exp_clean`
- **Salary Category** – kreirana K-Means klasterovanjem ($k = 3$, gde su plate u 3 kategorije(Low Salary, Medium Salary, High Salary)

U cilju sprečavanja curenja podataka (*data leakage*), sprovedena je selektivna integracija numeričkih atributa u zavisnosti od konkretne ciljne promenljive::

Tabela 2: Numerički atributi po ciljnoj promenljivoj

Target	**exp_clean**	**salary_clean**
Job Role		
Work Type		
Seniority	×	
Salary Category		×

Za Ciljnu promenljivu Seniority, `exp_clean` je isključen jer je direktno korišćen za njeno kreiranje. Analogno, `salary_clean` je isključen za ciljnu promenljivu Salary Category.

2.3 Kreiranje skupova atributa

TF-IDF vektorizacija primenjena je sa sledećim parametrima:

- `max_features = 15` (optimizovano eksperimentom)
- `stop_words = 'english'`

Tabela 3: Skupovi atributa korišćeni u analizi

Naziv	**Opis**	**Dimenzija**
Samo TF-IDF	TF-IDF vektorizacija teksta	$n \times 15$
Samo numerički	exp_clean i/ili salary_clean	$n \times 1$ ili $n \times 2$
Kombinovano	TF-IDF + numerički atributi	$n \times 16$ ili $n \times 17$

2.4 Kategorizacija plate – K-Means vs. Kvantili

Testirane su dve metode kategorizacije plate u tri klase (Low/Medium/High):

- **K-Means** ($k = 3$) – klasteruje plate na osnovu vrednosti

- **Kvantilni pristup** – deli na osnovu 33. i 66. percentila

Obe metode su postigle identičnu balansiranost klasa (0.997), što ukazuje na ravnomernu raspodelu plata u skupu podataka. Budući da je K-Means zadovoljio uslov balansiranosti ($0.997 > 0.7$), izabran je K-Means kao finalna metoda kategorizacije plate.

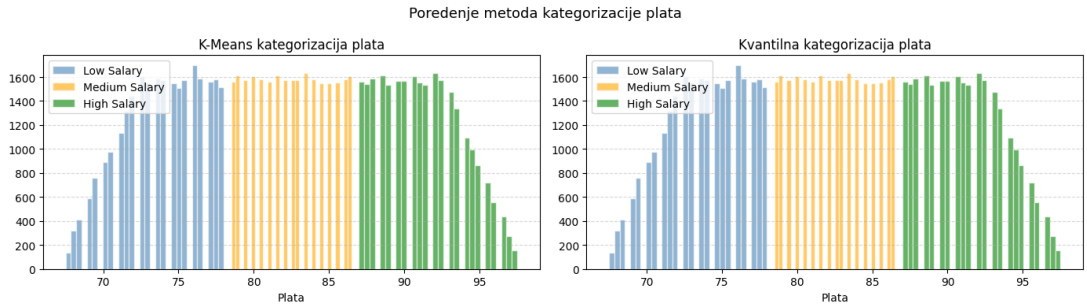

Slika 1: Poređenje K-Means i kvantilne kategorizacije plate

3 Metod

3.1 Radni tok: pregled

Kompletan analitički tok sastoji se od sledećih koraka:

1. Učitavanje i preprocesiranje podataka
2. Ekstrakcija numeričkih atributa i kreiranje ciljnih promenljivih
3. Kreiranje `num_map` rečnika – mapiranje ciljnih promenljivih na ispravne atribute
4. Analiza uticaja broja TF-IDF reči na meru preciznosti (Logistic Regression, Job Role)
5. Analiza kriterijuma grananja (Decision Tree, Job Role)
6. Poređenje skalera (MinMaxScaler vs. StandardScaler, svi targeti)
7. Podešavanje hiperparametara modela – GridSearchCV za DT i KNN (Job Role)
8. Treniranje svih 5 modela na sve 4 ciljne promenljive (20 eksperimenata)
9. Analiza uloge atributa (Feature Importance) (Random Forest)
10. Poređenje skupova atributa (samo tekst / samo broj / kombinacija)
11. Cross-validacija (5-fold) najboljeg modela po ciljnoj promenljivi

Svi zadaci su implementirani u Python-u koristeći `scikit-learn` biblioteku, sa fiksiranim `random_state=42` radi reproduktivnosti rezultata.

3.2 Analiza uticaja broja TF-IDF reči

Pre treniranja finalnih modela, analiziran je uticaj broja TF-IDF reči ($n \in \{10, 12, 14, 16, 18, 20\}$) na tačnost Logistic Regression klasifikatora za ciljnu promenljivu *Job Role*. Na osnovu ove analize odabrana je vrednost `max_features = 15` kao kompromis, jer veći broj reči povećava dimenzionalnost prostora i može dovesti do preprilagođavanja.

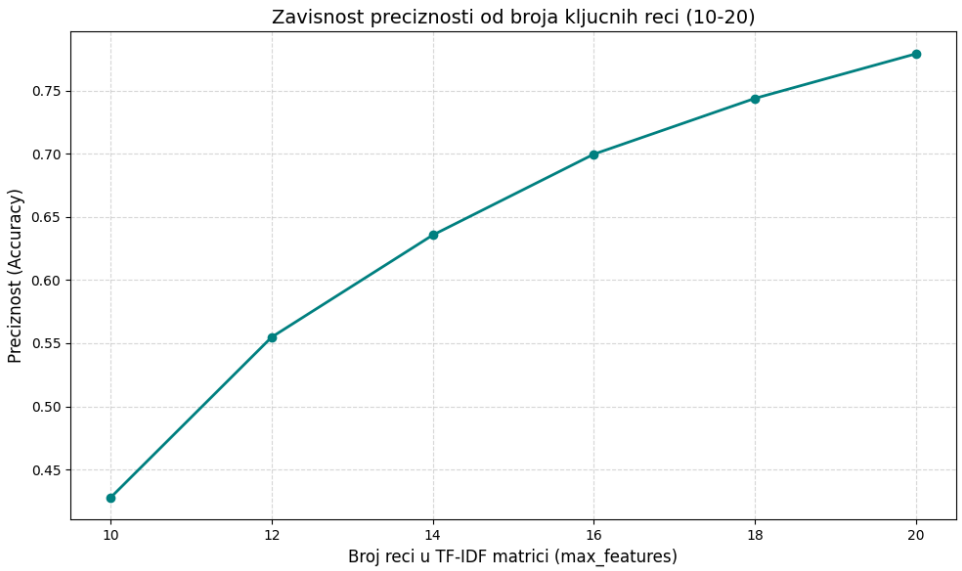

Slika 2: Uticaj broja TF-IDF reči na tačnost (Logistic Regression, Job Role)

3.3 Analiza kriterijuma – Decision Tree

Testirani su kriterijumi grananja za Decision Tree: *gini*, *entropy* i *log_loss*. Za svaki kriterijum i broj TF-IDF reči izmerena je tačnost na test skupu. Na osnovu tabele, možemo primetiti gotovo identične rezultate za svaki kriterijum.

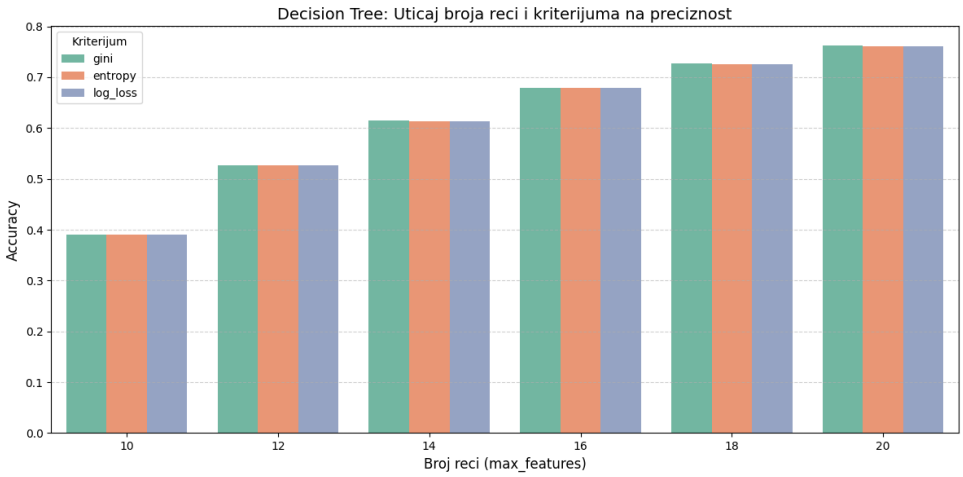

Slika 3: Uticaj različitih parametara i broja reči na tačnost(Decision Tree)

3.4 Poređenje skalera

Testiran je uticaj izbora skalera na tačnost svih 5 algoritama na sve 4 ciljne promenljive:

- **MinMaxScaler** – skalira vrednosti u interval $[0, 1]$
- **StandardScaler** – standardizuje na srednju vrednost 0 i standardnu devijaciju 1.

Izabran je MinMaxScaler sa prosečnom tačnošću 0.4293 naspram 0.4283 za StandardScaler.

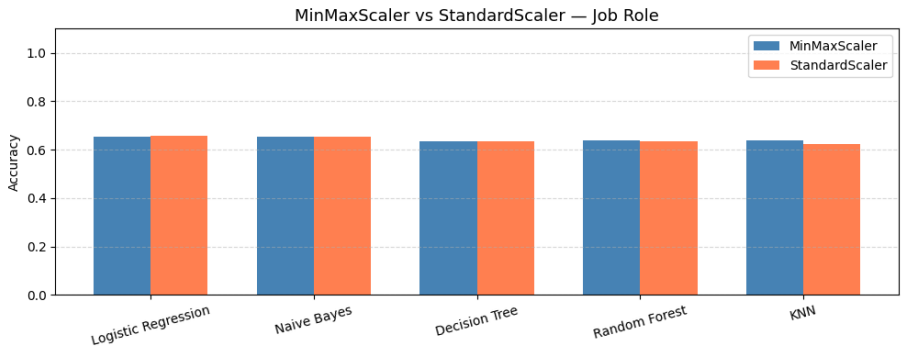

Slika 4: MinMaxScaler vs StandardScaler (Job Role)

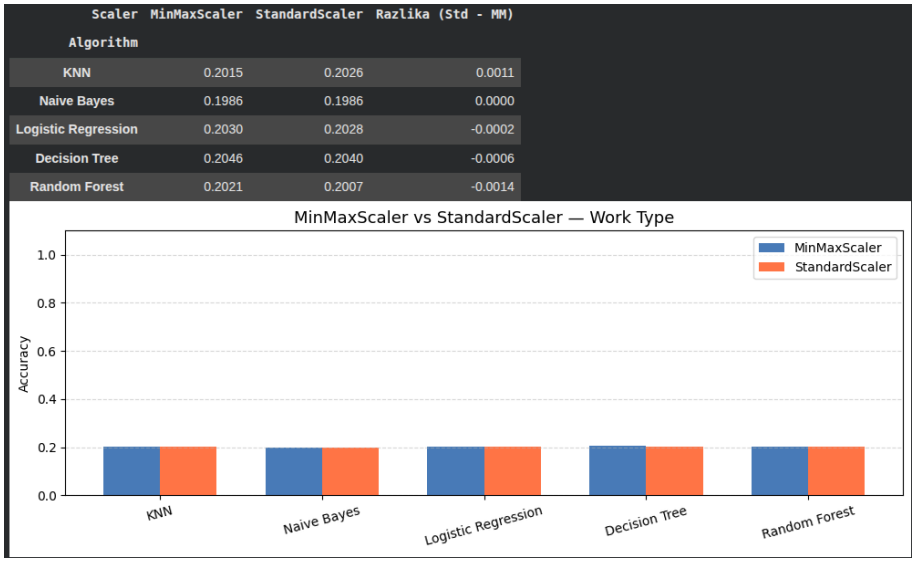

Scaler	MinMaxScaler	StandardScaler	Razlika (Std - MM)
Algorithm			
KNN	0.2015	0.2026	0.0011
Naive Bayes	0.1986	0.1986	0.0000
Logistic Regression	0.2030	0.2028	-0.0002
Decision Tree	0.2046	0.2040	-0.0006
Random Forest	0.2021	0.2007	-0.0014

Slika 5: MinMaxScaler vs StandardScaler (Work type)

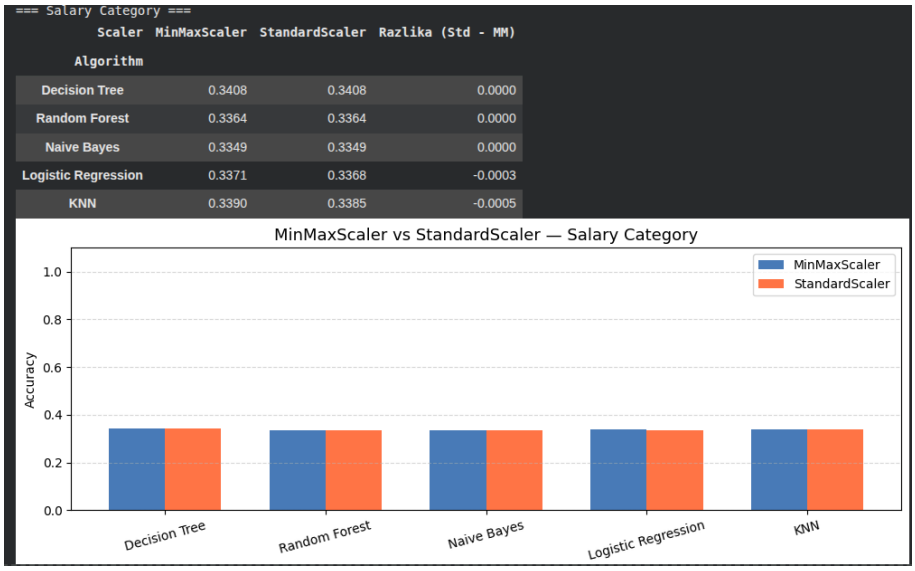

=== Salary Category ===

Scaler	MinMaxScaler	StandardScaler	Razlika (Std - MM)
Algorithm			
Decision Tree	0.3408	0.3408	0.0000
Random Forest	0.3364	0.3364	0.0000
Naive Bayes	0.3349	0.3349	0.0000
Logistic Regression	0.3371	0.3368	-0.0003
KNN	0.3390	0.3385	-0.0005

Slika 6: MinMaxScaler vs StandardScaler (Salary)

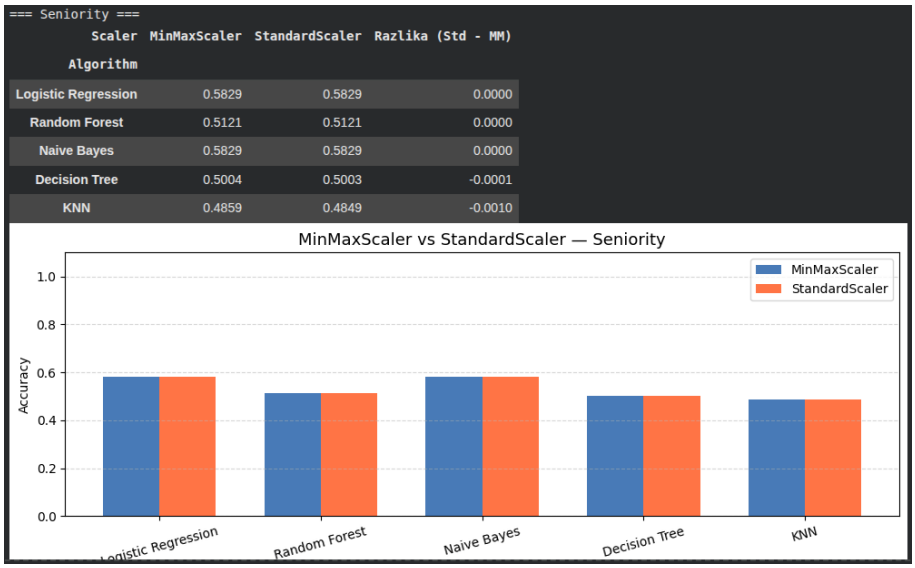

=== Seniority ===

Scaler Algorithm	MinMaxScaler	StandardScaler	Razlika (Std - MM)
Logistic Regression	0.5829	0.5829	0.0000
Random Forest	0.5121	0.5121	0.0000
Naive Bayes	0.5829	0.5829	0.0000
Decision Tree	0.5004	0.5003	-0.0001
KNN	0.4859	0.4849	-0.0010

Slika 7: MinMaxScaler vs StandardScaler (Seniority)

3.5 Podešavanje hiperparametara – GridSearchCV

Za Decision Tree i KNN primenjena je pretraga mreže (*GridSearchCV*) sa 5-fold unakrsnom validacijom na ciljnoj promenljivoj *Job Role* kao najzahtevnijom (najveći broj klasa). Optimalni parametri su zatim primenjeni na sve ciljne promenljive.

Tabela 4: Prostor pretrage hiperparametara

Algoritam	**Hiperparametar**	**Vrednosti**
Decision Tree	`max_depth`	[5, 10, None]
	`min_samples_leaf`	[1, 5]
	`criterion`	[gini, entropy]
KNN	`n_neighbors`	[3, 5, 7, 11, 15]
	`weights`	[uniform, distance]
	`metric`	[euclidean, manhattan]

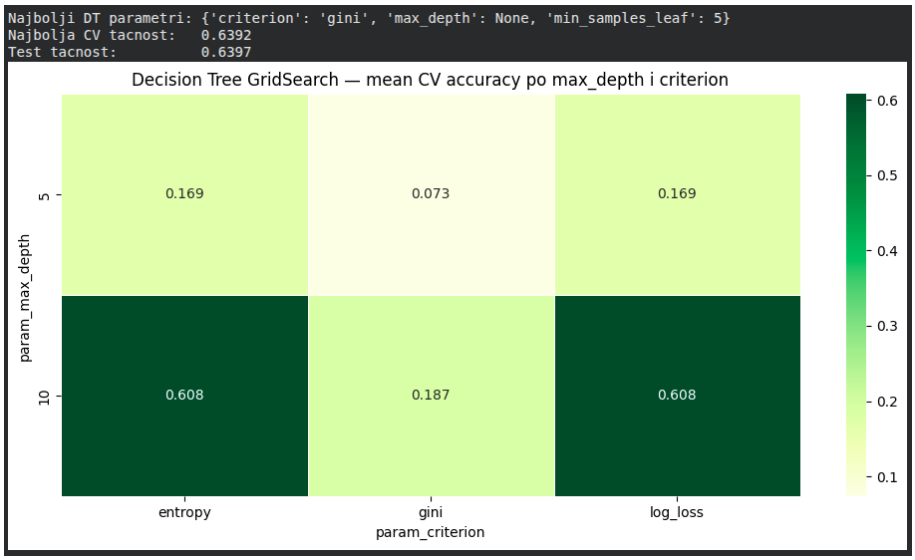

Slika 8: Zavisnost tačnosti DCT modela od izbora hiperparametara

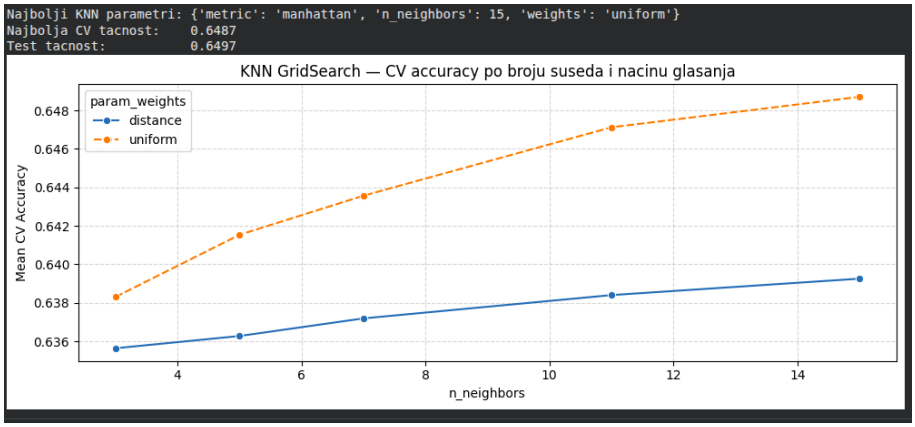

Slika 9: Zavisnost tačnosti KNN modela od izbora hiperparametara

Dobijeni optimalni parametri za Decision Tree: `criterion = gini`, `max_depth = None`, `min_samples_leaf = 5`, CV tačnost: 0.6392, a za KNN: `metric = manhattan`, `n_neighbors = 15`, `weights = uniform`, CV tačnost: 0.6487.

3.6 Algoritmi klasifikacije

3.6.1 Logistic Regression

Linearni model koji procenjuje verovatnoće klasa. Parametri: `max_iter=1000`.

3.6.2 Decision Tree

Algoritam koji rekurzivno razdvaja prostor atributa po kriterijumu *Gini indeksa*. Koriste se optimalni parametri dobijeni GridSearchCV: `criterion = gini`, `max_depth = None`, `min_samples_leaf = 5`.

3.6.3 Random Forest

Ansambalni metod koji trenira 100 stabala odlučivanja na nasumičnim podskupovima podataka i atributa. Parametri: `n_estimators=100`, `random_state=42`.

3.6.4 K-Nearest Neighbors (KNN)

Klasifikuje instancu na osnovu k najbližih suseda u prostoru atributa. Koriste se optimalni parametri dobijeni GridSearchCV, `metric = manhattan`, `n_neighbors = 15`, `weights = uniform`.

3.6.5 Naive Bayes

Probabilistički klasifikator zasnovan na Bajesovoj teoremi uz pretpostavku nezavisnosti atributa. Implementacija: `GaussianNB`.

3.7 Metrike evaluacije

3.7.1 Tačnost (Accuracy)

$$\text{Accuracy} = \frac{\text{TP} + \text{TN}}{\text{TP} + \text{TN} + \text{FP} + \text{FN}} \tag{3}$$

Gde su:

- **TP (True Positive):** Stvarno pozitivni, predviđeni kao pozitivni.
- **TN (True Negative):** Stvarno negativni, predviđeni kao negativni.
- **FP (False Positive):** Stvarno negativni, predviđeni kao pozitivni.
- **FN (False Negative):** Stvarno pozitivni, predviđeni kao negativni.

3.7.2 Makro F1 mera

$$F1_{\text{macro}} = \frac{1}{K} \sum_{k=1}^{K} \frac{2 \cdot P_k \cdot R_k}{P_k + R_k} \tag{4}$$

gde su P_k i R_k preciznost i odziv za klasu k, a K ukupan broj klasa. Makro F1 tretira sve klase ravnopravno, što je posebno važno pri nebalansiranoj distribuciji klasa kao u slučaju *Job Role* ciljne promenljive.

3.7.3 Cross - validacija

Primenjena je 5-fold unakrsna validacija na celom uzorku za svaki par (najbolji model, ciljna promenljiva), koristeći `Pipeline` koji uključuje vektorizaciju, skaliranje i klasifikaciju. Ovo daje pouzdaniju procenu generalizacije od jednog train/test splita.

4 Rezultati i vizualizacije

4.1 Vizualizacija podataka – 2D PCA

Radi boljeg razumevanja strukture podataka, primenjena je analiza glavnih komponenti (PCA) sa redukcijom na 2 dimenzije. Za svaku ciljnu promenljivu prikazan je raspored instanci u dvodimenzionalnom prostoru.

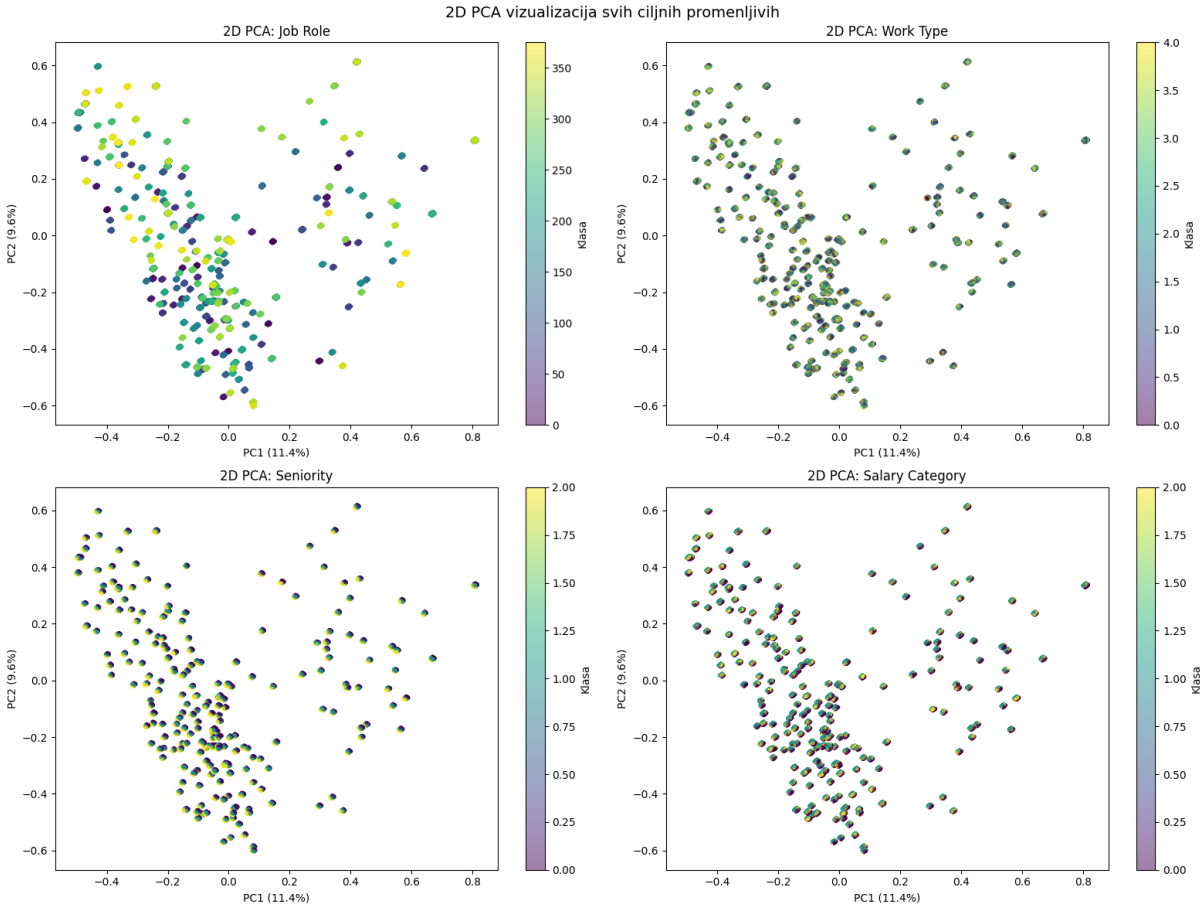

Slika 10: 2D PCA vizualizacija ciljnih promenljivih

Na osnovu PCA vizualizacije, primećujemo da klase nisu razdvojive ni za jednu ciljnu promenljivu u dvodimenzionalnom prostoru. Prve dve glavne komponente objašnjavaju ukupno 20.92 % varijanse podataka, što ukazuje na visoku dimenzionalnost i složenost prostora atributa.

4.2 Rezultati klasifikacije – Job Role

Tabela 5: Rezultati za ciljnu promenljivu Job Role (poređani po Macro F1)

Algoritam	**Accuracy**	**Macro F1**	**Vreme (s)**
Random Forest	0.6373	0.6031	27.73
Decision Tree	0.6397	0.6015	0.40
KNN	0.6497	0.5994	0.01
Naive Bayes	0.6555	0.5818	0.07
Logistic Regression	0.6552	0.5773	33.31

Izabrani model: Decision Tree (dostupan kao sačuvani model, drugi po Macro F1).

4.3 Rezultati klasifikacije – Work Type

Tabela 6: Rezultati za ciljnu promenljivu Work Type (poređani po Macro F1)

Algoritam	**Accuracy**	**Macro F1**	**Vreme (s)**
Random Forest	0.2021	0.2021	14.405
Logistic Regression	0.2030	0.2015	0.31
Naive Bayes	0.1986	0.1977	0.032
KNN	0.1980	0.1951	0.004
Decision Tree	0.1962	0.1941	0.395

Izabrani model: Logistic Regression (slični rezultati kao kod Random Foresta). Napomena: niske tačnosti (0.2021) ukazuju na složenost klasifikacije ovog ciljnog atributa.

4.4 Rezultati klasifikacije – Seniority

Tabela 7: Rezultati za ciljnu promenljivu Seniority (poređani po Macro F1)

Algoritam	**Accuracy**	**Macro F1**	**Vreme (s)**
Random Forest	0.5121	0.3160	7.20
Decision Tree	0.5190	0.3073	0.25
KNN	0.5539	0.2758	0.004
Logistic Regression	0.5829	0.2455	0.34
Naive Bayes	0.5829	0.2455	0.02

Izabrani model: Random Forest (najbolji Macro F1 = 0.3160).

4.5 Rezultati klasifikacije – Salary Category

Tabela 8: Rezultati za target Salary Category (poređani po Macro F1)

Algoritam	Accuracy	Macro F1	Vreme (s)
Decision Tree	0.3411	0.3393	0.246
Logistic Regression	0.3371	0.3365	0.186
Random Forest	0.3364	0.3363	6.12
Naive Bayes	0.3349	0.3338	0.022
KNN	0.3346	0.3332	0.007

Izabrani model: Decision Tree (prvi po obe metrike).

4.6 Zbirni rezultati

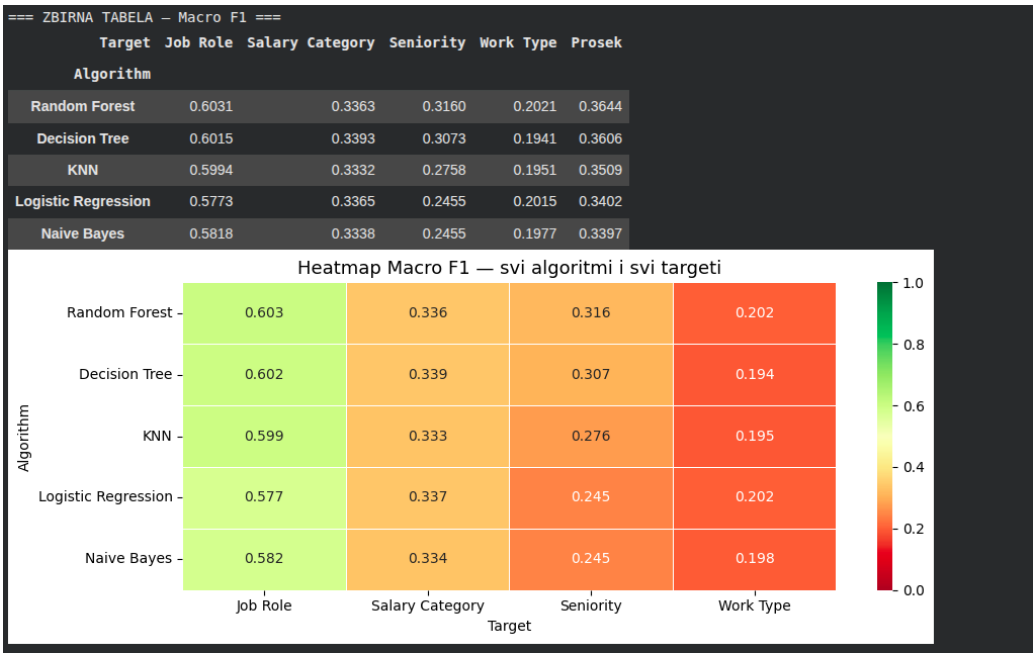

=== ZBIRNA TABELA – Macro F1 ===

Target / Algorithm	Job Role	Salary Category	Seniority	Work Type	Prosek
Random Forest	0.6031	0.3363	0.3160	0.2021	0.3644
Decision Tree	0.6015	0.3393	0.3073	0.1941	0.3606
KNN	0.5994	0.3332	0.2758	0.1951	0.3509
Logistic Regression	0.5773	0.3365	0.2455	0.2015	0.3402
Naive Bayes	0.5818	0.3338	0.2455	0.1977	0.3397

Slika 11: Heatmapa makro F1 mere za sve algoritme i ciljne promenljive

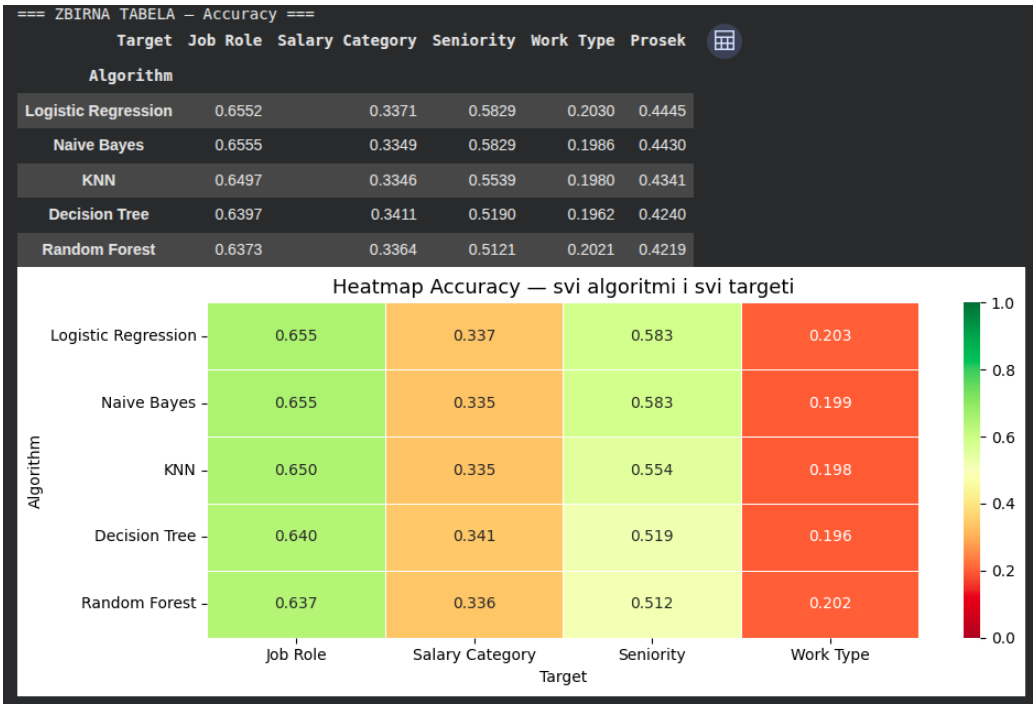

=== ZBIRNA TABELA — Accuracy ===

Target / Algorithm	Job Role	Salary Category	Seniority	Work Type	Prosek
Logistic Regression	0.6552	0.3371	0.5829	0.2030	0.4445
Naive Bayes	0.6555	0.3349	0.5829	0.1986	0.4430
KNN	0.6497	0.3346	0.5539	0.1980	0.4341
Decision Tree	0.6397	0.3411	0.5190	0.1962	0.4240
Random Forest	0.6373	0.3364	0.5121	0.2021	0.4219

Slika 12: Heatmapa accuracy mere za sve algoritme i ciljne promenljive

4.7 Cross-validacija

Tabela 9: Cross-validacija (5-fold) najboljeg modela po ciljnoj promenljivi

Ciljna promenljiva	Algoritam	CV Mean	CV Std
Job Role	Decision Tree	0.6418	0.0008
Work Type	Logistic Regression	0.1964	0.0025
Seniority	Random Forest	0.5505	0.0039
Salary Category	Decision Tree	0.3276	0.0046

4.8 Analiza uloge atributa

Na osnovu DCT modela za svaki target identifikovane su najvažnije reči iz TF-IDF reprezentacije i numerički atributi.

Tabela 10: Najvažniji atribut po ciljnoj promenljivoj (Decision Tree)

Ciljna promenljiva	Atribut	Važnost
Job Role	perfomance	0.08
Work Type	salary_clean	0.397
Seniority	salary_clean	0.497
Salary Category	exp_clean	0.445

Na osnovu ove tabele, primećujemo da važnost atributa kod Job Role ciljne promenljive je raspršena. Dok za ciljnu promenljivu Work Type dominiraju 2 atributa (salary_clean i exp_clean), a za ostale dve ciljne promenljive imamo dominaciju jednog atributa.

4.9 Poređenje skupova atributa

Tabela 11: Poređenje skupova atributa (RandomForest) po ciljnoj promenljivoj

Ciljna promenljiva	Svi atributi	Tekstualni	Numerički
Job Role	0.64	0.66	0.01
Work Type	0.20	0.20	0.20
Seniority	0.51	0.58	0.58
Salary Category	0.34	0.34	0.33

Tabela prikazuje znatno veći uticaj tekstualnih atributa u odnosu na numeričke kod *Job Role* ciljne promenljive, kod *Seniority* dobijamo slične rezultate (0.58), dok kod *Work Type* i *Salary Category* ne postoji razlika u rezultatima.

5 Diskusija i zaključak

5.1 Analiza rezultata

Job Role ciljna promenljiva je prirodna za ovaj skup podataka jer tekst u koloni Responsibilities direktno opisuje šta neko radi na poslu te se stoga postiže tačnost oko 64–66% što je solidan rezultat za višeklasnu klasifikaciju sa velikim brojem klasa. Makro F1 od 0.60 potvrđuje da model ravnomerno prepoznaje različite kategorije poslova. Decision Tree sa `max_depth=None` pokazuje da podaci zahtevaju dublje stablo za adekvatno razdvajanje klasa.

Work Type pokazuje niske tačnosti (0.20), bliske nasumičnom pogađanju. Ovo ukazuje da tekstualni opis odgovornosti ne sadrži dovoljno informacija za predviđanje tipa radnog angažmana (Contract/Full-Time/Intern/Part-Time/Temporary), što je razumljivo.

Seniority pokazuje veću razliku između Accuracy (0.58) i Macro F1 (0.31). Ovo sugeriše da model dobro predviđa dominantnu klasu ali loše ostale, što je posledica nebalansiranosti klasa, takođe model pokušava da iz teksta odgovornosti zaključi nivo iskustva a isti tekst odgovornosti može biti u oglasu i za npr. Junior-a i Senior-a.

Salary Category postiže tačnost od 0.34, što odgovara nasumičnom pogađanju za 3 klase (tačnost = 0.33). Nakon što je `salary_clean` isključen iz atributa za ovu ciljnu promenljivu, model predviđa kategoriju plate isključivo iz teksta i iskustva, što je znatno teži zadatak jer

Izbor skalera: MinMaxScaler je pokazao zanemarujuće bolje rezultate (0.4293 vs 0.4283), što je konzistentno sa teorijskim očekivanjima jer TF-IDF vrednosti su već u $[0, 1]$.

5.2 Napomena o numeričkim atributima

U prvobitnoj verziji koda, `exp_clean` i `salary_clean` su korišćeni kao atributi za *sve* ciljne promenljive, uključujući Seniority i Salary Category koji su direktno kreirani iz ovih kolona. To je dovodilo do veštački visokih rezultata (tačnost i Macro F1 mera blizu 1.0) zbog curenja podataka. U finalnoj verziji koda, uvedeni su odvojeni skupovi atributa (`num_map`) koji isključuju pomenute atribute za odgovarajuće ciljne promenljive.

5.3 Ograničenja

- **Uzorkovanje:** Korišćeno je samo 5% originalnog skupa. Rezultati mogu varirati na celom skupu.
- **Reprezentacija teksta:** TF-IDF sa 15 reči je korišćena reprezentacija. Veće vrednosti (50, 100, 500) bi potencijalno mogle dati bolje rezultate klasifikacije.
- **Work Type i Salary Category:** Kod ovih ciljnih promenljivih dobili smo niske perfomanse udelom i što smo koristili parametre modela za Job Role ciljnu promenljivu.
- **GridSearch:** Optimizacija hiperparametara izvršena je samo za Job Role ciljnu promenljivu. Posebna optimizacija po svakoj ciljnoj promenljivi bi mogla poboljšati rezultate.

5.4 Zaključak

Ovaj rad predstavlja kompletan tok mašinskog učenja primenjen na klasifikaciju opisa radnih mesta — od preprocesiranja sirovog teksta do evaluacije modela. U okviru istraživanja testirano je 5 algoritama na 4 ciljne promenljive, što čini ukupno 20 eksperimenata, uz analizu uticaja preprocesiranja, optimizacije hiperparametara i odabira skupa atributa.

Ključni doprinosi rada su:

1. Poređenje skupova atributa (RandomForest) u okviru pokazalo je da tekstualni atributi dominantno doprinose klasifikaciji, dok numerički atributi (iskustvo, plata) imaju zanemarljiv samostalan doprinos.
2. Poređenje MinMaxScaler vs. StandardScaler pokazalo je marginalnu prednost MinMaxScalera.
3. Optimizacija hiperparametara putem GridSearchCV za ciljnu promenljivu Job Role identifikovala je optimalne parametre Decision Tree i KNN algoritama.
4. Cross-validacija potvrdila je stabilnost rezultata (niska standardna devijacija).
5. PCA vizualizacija potvrdila je da klase nisu linearno razdvojive, što se poklapa sa dobijenim performansama modela.
6. Analiza važnosti atributa (Decision Tree) identifikovala je ključne reči i važnost numeričkih atributa po svakoj ciljnoj promenljivoj.
7. Poređenje pet klasifikacionih algoritama na četiri ciljne promenljive omogućilo je identifikaciju najadekvatnijeg algoritma po ciljnoj promenljivi.

Naprednija verzija rada trebalo bi da se fokusira na primeni naprednijih metoda reprezentacije teksta, treniranje i testiranje na celom skupu podataka bez uzorkovanja, kao i posebnu optimizaciju hiperparametara za svaku ciljnu promenljivu.